



UNIVERSIDADE PRESBITERIANA MACKENZIE

Faculdade de Computação e Informática

Prof. Dr. Ivan Carlos Alcântara de Oliveira

Inteligência Artificial – 7º CC

Projeto da Disciplina em Grupo



Aplicação de Inteligência Artificial em Problema Real

Parte 1 - Informações

Turma: 7º G (**X**) 7º N ()

(Mínimo 3 e Máximo. 5 integrantes)

Nome do Integrante	RA
Beatriz Aparecida de Mello Barbosa	10354067
Bruna Gonçalves Corte David	10425696
Henrique Brainer Costa	10420717
João Pedro Queiroz de Andrade	10425822
Júlia Andrade	10428513

Considerando os assuntos que serão abordados na disciplina de Inteligência Artificial (IA) ou tópicos relacionados à área de IA, refletir sobre uma proposta de projeto a ser trabalhado dentro deste semestre.

Caso o seu Trabalho de Conclusão de Curso (TCC) esteja aderente ao conteúdo da disciplina, pode ser aproveitado como projeto. Devido a isso, o projeto pode ser realizado de forma individual ou em grupo, com a quantidade de alunos que estão fazendo o TCC. Caso contrário, este projeto deve ser realizado por no mínimo 3 e no máximo 5 alunos.

O objetivo deste projeto é aplicar os conceitos e técnicas de IA para implementação de soluções na área de Negócios, Educação e Saúde ou qualquer problema de outra área no qual o uso da IA permita melhorar/otimizar o seu funcionamento e/ou fazer previsões e/ou melhorar a qualidade de vidas das pessoas e que estejam alinhadas aos Objetivos do Desenvolvimento Sustentável (ODS) para a humanidade, na tarefa de dissociar o crescimento econômico da pobreza, da desigualdade e das mudanças climáticas. A saber, os 17 objetivos ODS são:



Para saber mais sobre os ODS, sugere-se consultar:

- Indicadores Brasileiros para os Objetivos de Desenvolvimento Sustentável:
<https://odsbrasil.gov.br/>
- Guia Agenda 2030: www.guiaagenda2030.org/



UNIVERSIDADE PRESBITERIANA MACKENZIE

Faculdade de Computação e Informática

Prof. Dr. Ivan Carlos Alcântara de Oliveira

Inteligência Artificial – 7º CC



O projeto deve empregar dados reais, isto é, **dados próprios de uma empresa ou negócio ou obtidos de um local com *dataset* público, como o Kaggle¹, ou capturados pelo grupo** (na dúvida sobre a validade dos dados a ser empregado, consulte o professor).

Apresentar a seguir os detalhes da proposta do seu projeto. As informações publicadas neste documento serão utilizadas pelo professor para verificar a aderência à disciplina e sua viabilidade.

A entrega deste documento, convertido para PDF, juntamente com o arquivo da Rubrica Analítica, em Word, devidamente preenchidos, deve ser realizada pelo Ambiente Virtual de Aprendizagem (AVA). O peso desta atividade corresponde a uma atividade (exercício) da disciplina. Basta um dos integrantes do grupo efetuar o envio deste documento pelo AVA no prazo máximo configurado.

Informações sobre a Proposta de Projeto\

1. **Título provisório:** [Classificação Automática de Atividades Culturais e Educacionais](#)

2. **Área/Tema relacionado(a):** [Educação e Cultura](#)

(Por ex.: saúde, transportes, entretenimento, *smart cities*, negócios, educação, redes sociais, sistemas de recomendação etc.)

3. **ODS(s) associada(s) e justificativa(s) (descrever de forma sucinta):**

A má categorização de atividades educacionais e culturais oferecidas por instituições como o SESC e as Fábricas de Cultura impõe barreiras que atrapalham usuários a facilmente descobrirem um curso, oficina, ou outro meio de educação do seu interesse. Além disso, esta má categorização atrapalha as próprias instituições a filtrarem suas atividades mais eficientemente para que alcancem a audiência correta. Isto reduz diretamente o alcance das atividades com seu público alvo correto, e consequentemente as oportunidades de educação. Logo, nossa proposta está associada à **ODS 4**, pois contribui com a meta de **Educação de Qualidade**.

Além disso, a dificuldade de encontrar atividades educacionais e culturais adequadas não afeta todos os usuários da mesma forma: pessoas com mais tempo, familiaridade digital ou repertório cultural conseguem filtrar catálogos mal categorizados com mais facilidade, enquanto outras acabam desistindo de buscar ou nem chegam a descobrir a atividade certa. Isto amplia uma desigualdade de acesso a oportunidades de educação e cultura. Logo, ao reduzir essa barreira de descoberta, nossa proposta também contribui com a meta de **Redução das Desigualdades da ODS 10**.

¹ <https://www.kaggle.com/datasets>



4. Tópico(s) de IA que pretende abordar (descrever a seguir):

Processamento de Linguagem Natural (PLN), geração de embeddings semânticos de texto a partir de um modelo de linguagem em português, e aprendizado de máquina para classificar o conteúdo em categorias.

5. Descrição da sua proposta:

Realizar uma descrição resumida a respeito do problema do mundo real ao qual o seu projeto está inserido nas subseções a seguir.

5.1. Contextualização

Instituições como o SESC e as Fábricas de Cultura oferecem um grande volume de atividades (cursos, oficinas, apresentações e eventos), divulgadas em seus sites institucionais. Essas atividades são organizadas em categorias, com a finalidade de facilitar tanto a navegação no site quanto de separar os tipos diferentes de interesses para guiar o público alvo para as atividades que correspondem com ele. Porém, notamos que muitas destas atividades não estão categorizadas com a devida precisão, ao ponto de que há categorias genéricas demais que englobam atividades muito diferentes. Por exemplo, "Tecnologia e Artes" é uma categoria real dos dados que obtivemos, que pode agrupar, sob a mesma etiqueta, um curso de programação e um curso de pintura. Além disso, notamos, pelos dados, que algumas atividades não recebem todas as categorias diferentes as quais podem se encaixar, ou que há duas categorias que se referem à mesma coisa, pouco específicas, etc. Essa categorização ineficiente dificulta a busca de quem consulta o site em torno de um interesse específico e reduz a efetividade da divulgação das atividades oferecidas.

5.2. Objetivo

Desenvolver uma API que recebe a descrição textual de uma atividade cultural e/ou educacional e retorna automaticamente a(s) categoria(s) mais específica(s) e coerente com seu conteúdo. Essa categoria vem de embeddings semânticos gerados por um modelo de linguagem em português, combinados a um classificador treinado neste projeto com dados reais de atividades do SESC e das Fábricas de Cultura. A API deve poder ser integrada por qualquer instituição que publique esse tipo de atividade.



5.3. Motivação

Atividades culturais e educacionais são temporárias, algumas podem ser encontros semanais, outras têm data de inscrição e término. Muitas atividades deixam de existir em menos de um mês, elas expiram, o que é muito diferente de itens de catálogo permanentes como filmes ou livros. Este alto grau de rotatividade torna inviável tanto a reclassificação manual contínua quanto uma abordagem por comparação simples de banco de dados, pois, além disso, o vocabulário das descrições das atividades variam bastante entre si e podem ser formal ou informal. Uma classificação automática, capaz de compreender o conteúdo semântico do texto num todo, é a alternativa que acompanha o ritmo de renovação do catálogo e o vocabulário variado das descrições das atividades. Esta abordagem é benéfica para os usuários, que passam a encontrar atividades mais alinhadas a seus interesses, e para as instituições, que ganham um catálogo mais navegável sem custo adicional de curadoria manual.

Nós realizamos, inclusive, que essa categorização genérica (misturar cursos de tecnologia e de artes numa única etiqueta, por exemplo) existe justamente porque as instituições não têm tempo ou um sistema para reclassificar atividades que mudam com essa frequência. Se essa suspeita estiver correta, ela reforça a necessidade do projeto. Logo, porque nosso projeto será desenhado como uma API independente da infraestrutura de cada instituição, a solução pode, em princípio, ser adotada por qualquer site (tanto de instituições privadas quanto públicas) que publique esse tipo de atividade: bastaria enviar o texto da descrição para receber as categorias sugeridas em resposta.

5.4. Justificativa

A abordagem escolhida combina embeddings semânticos, gerados por um modelo de linguagem em português pré-treinado, com um classificador a ser treinado neste projeto. Como já vimos, o vocabulário das descrições varia bastante de uma atividade para outra, então a outra alternativa, que seria uma comparação simples por palavras-chave, teria dificuldade em lidar com isso, porque ela olha palavra por palavra: duas descrições da mesma atividade, escritas em estilos diferentes, acabariam parecendo coisas diferentes pra esse tipo de comparação. Embeddings resolvem isso porque capturam o sentido do texto como um todo, não apenas as palavras isoladas.

Antes de treinar o classificador, pretendemos usar esses mesmos embeddings para agrupar automaticamente as descrições parecidas (uma clusterização), e então nomear manualmente cada grupo que aparecer, criando assim as categorias que vão servir de gabarito de treino. Acreditamos que seja viável fazer isso manualmente, porque as categorias atuais não são muitas, então conseguimos revisar os agrupamentos num tempo razoável.



5.5. Dados - (subseção adicionada)

Os dados já foram capturados com técnicas de *web scraping* em Python para o projeto da disciplina teoria dos grafos, realizada semestre passado e serão atualizados para este projeto, seguindo o mesmo processo. Do SESC, a coleta é feita direto pelo endpoint JSON que o próprio site usa para carregar sua programação, via requisições HTTP simples, cobrindo 8 unidades (Casa Verde, Santana, Consolação, Avenida Paulista, 14 Bis, Centro de Pesquisa e Formação, CineSesc e Pompeia) e reunindo hoje 526 atividades, com campos como nome, unidade, categorias (podendo ter mais de uma por atividade), datas de sessão, valor, e link. Porém, a versão atual dessa coleta não inclui a descrição completa da atividade, então essa etapa precisa ser revisitada antes do treino do classificador, já que o texto da descrição é a principal fonte de sinal para os embeddings. Das Fábricas de Cultura, a coleta é feita por automação de navegador, através da biblioteca Selenium do Python, simulando cliques no site e abrindo as informações de cada atividade para capturar nome, categoria, unidade, data e a descrição completa, reunindo hoje 61 atividades, cobrindo 2 unidades (Vila Nova Cachoeirinha e Brasilândia), o que também precisará ser expandido para termos uma base mais representativa. Como as categorias atuais são o próprio problema, a rotulagem vai partir de uma clusterização automática das descrições por similaridade e da definição manual, pelo grupo, do nome de cada categoria que aparecer.



5.6. Contribuições esperadas

Uma contribuição de um projeto corresponde ao principal resultado ou valor agregado produzido pelo trabalho, demonstrando como técnicas de IA foram aplicadas, avaliadas ou integradas para compreender, apoiar ou solucionar, ainda que parcialmente, o problema real investigado. O Quadro 1 apresenta qual ou quais contribuições um projeto poderia alcançar em variadas dimensões.

Quadro 1. Dimensões e contribuições que um projeto de IA pode alcançar

Dimensão	Contribuição que o projeto pode alcançar	Exemplo
Compreensão do problema	Formalizar um problema real como uma tarefa de IA	Transformar previsão de evasão acadêmica em um problema de classificação
Dados	Construir, integrar, limpar ou caracterizar uma base de dados	Consolidar dados meteorológicos de diferentes estações e tratar valores ausentes
Modelagem	Desenvolver e comparar modelos de IA	Comparar Random Forest, MLP e XGBoost para prever demanda
Experimentação	Estabelecer um protocolo experimental adequado	Separar treino/teste, usar validação cruzada e métricas apropriadas
Avaliação	Demonstrar quantitativamente vantagens e limitações	Mostrar que determinado modelo aumenta o F1-score, mas possui maior custo computacional
Explicabilidade	Investigar por que o modelo toma determinadas decisões	Usar SHAP para identificar quais atributos influenciam uma classificação
Aplicação	Incorporar o modelo em um protótipo funcional	Criar uma aplicação Web que utiliza o modelo treinado
Impacto	Demonstrar como a solução pode apoiar decisões reais	Identificar áreas ou períodos com maior risco de acidentes
Reprodutibilidade	Organizar código, dados e experimentos de maneira reproduzível	Disponibilizar notebooks, configuração dos experimentos e documentação
Análise crítica	Identificar limitações, riscos e possibilidades de evolução	Discutir viés dos dados, generalização e necessidade de dados reais adicionais



Quadro 2. Dimensões e contribuições que *NOSSO* projeto de IA pode alcançar

Dimensão	Contribuição que o projeto pode alcançar
Compreensão do problema	A proposta trata a categorização ampla e imprecisa das atividades como um problema de classificação de texto.
Dados	Montaremos uma base de atividades categorizadas a partir dos dados reais do SESC e das Fábricas de Cultura. Como as categorias atuais são o próprio problema, a rotulagem vai partir de uma clusterização automática das descrições por similaridade e da definição manual do nome de cada categoria que aparecer.
Modelagem	Faremos a comparação entre diferentes formas de representar o texto (por exemplo, comparar TF-IDF que conta a frequência das palavras sem entender significado com embeddings do modelo de linguagem em português) com diferentes classificadores (por exemplo, diferentes maneiras de tratar o vetor de números gerados para “desenhar a linha de corte” entre as categorias (regressão logística, SVM, MLP, para citar alguns métodos)).
Experimentação	Os dados serão divididos em treino, validação e teste, com validação cruzada e métricas adequadas a um problema com desbalanceamento entre categorias na base de dados (mais da metade são categorizadas como oficinas, por exemplo).
Avaliação	As abordagens testadas serão comparadas por métricas como precisão dos resultados e F1-score, além do custo computacional de cada uma.
Explicabilidade	Investigaremos quais termos ou trechos das descrições mais pesam nas categorias escolhidas pelo modelo.
Aplicação	O resultado final é um protótipo de API que recebe a descrição de uma atividade e devolve as categorias sugeridas.
Impacto	A categorização mais precisa facilita a navegação dos usuários nos sites das instituições que poderiam adotar a API. Além disso, ajuda as instituições a melhorarem o alcance das atividades com o seu público alvo e facilita o acompanhamento da alta rotatividade destas atividades. O projeto beneficiará os dois lados e contribuirá com a difusão de educação e cultura.
Reprodutibilidade	A documentação dos experimentos e uma amostra do dataset ficarão num repositório público no GitHub.
Análise crítica	Discutiremos as limitações da base de dados, como volume disponível, desbalanceamento entre categorias e viés de vir de só duas instituições, além da necessidade de validação humana.



6. Outras Informações:

6.1. Pretende utilizar em outras disciplinas:

() Sim (**X**) Não

Caso seja utilizado em outras disciplinas, informe quais:

- Nome Disciplina 1:
- Nome Disciplina 2:
- Nome Disciplina 3:

6.2. Esta proposta está relacionada ao TCC:

() Sim (**X**) Não

Caso positivo, informe o nome do(a) professor(a) orientador(a):

Declaração de uso de IA generativa

Marcar uma das opções:

- () Não foram utilizadas ferramentas de IA generativa nesta atividade.
(**X**) Foi utilizada, conforme abaixo.

Discriminar a(s) ferramenta(s) utilizada(s):

Claude (Anthropic)

Para quê (marque todas que se aplicam):

- (**X**) Compreender enunciado, conceito ou material da disciplina
(**X**) Diagnosticar erro em algo que já havia produzido
() Produzir parte do conteúdo entregue
(**X**) Revisar ou reescrever conteúdo que já havia produzido
(**X**) Traduzir, formatar ou redigir texto de apoio
(**X**) Outro (Discriminar): Conferir se o projeto proposto pelo grupo era viável e ajudar a estudar as tecnologias de IA necessárias para o projeto. A ideia de proposta, motivações, justificativas, etc, foram pensadas pelo grupo por conta própria.

O grupo declara que compreende e é capaz de explicar integralmente o que foi entregue.