

Classificação Automática de Atividades Culturais e Educacionais

Beatriz Aparecida de Mello Barbosa (RA: 10354067)¹,
Bruna Gonçalves Corte David (RA: 10425696)¹,
Henrique Brainer Costa (RA: 10420717)¹,
João Pedro Queiroz de Andrade (RA: 10425822)¹,
Júlia Andrade (RA: 10428513)¹

¹ Faculdade de Computação e Informática (FCI) – Universidade Presbiteriana Mackenzie
São Paulo – SP – Brasil

Abstract. *This article presents the development of an Artificial Intelligence-based solution for the automated classification of cultural and educational activities based on their descriptions. To overcome the problem of imprecise categorization in event catalogs, the proposed architecture employs Natural Language Processing (NLP) techniques. The approach combines the generation of semantic embeddings from a pre-trained Portuguese model with machine learning classifiers (such as SVM or MLP). The application aims to optimize search and recommendation platforms, ensuring that activities with high turnover are categorized accurately and efficiently, eliminating the need for continuous manual curation. At this stage, 693 activities from two institutions were collected and characterized, providing quantitative evidence of the inadequacy of the categories currently in use. Clustering the activity descriptions produced a set of 13 categories, two of which do not exist in the original catalogs.*

Resumo. *Este artigo apresenta o desenvolvimento de uma solução baseada em Inteligência Artificial para a classificação automatizada de atividades culturais e educacionais a partir de suas descrições. Para contornar o problema da categorização imprecisa de catálogos de eventos, a arquitetura proposta emprega técnicas de Processamento de Linguagem Natural (PLN). A abordagem alia a geração de embeddings semânticos de um modelo pré-treinado em português a classificadores de aprendizado de máquina (como SVM ou MLP). A aplicação visa otimizar plataformas de busca e recomendação, garantindo que atividades com alta rotatividade sejam categorizadas de forma precisa e eficiente, dispensando a curadoria manual contínua. Nesta etapa foram coletadas e caracterizadas 693 atividades de duas instituições, evidenciando-se de forma quantitativa a inadequação das categorias atualmente adotadas. A partir do agrupamento das descrições obteve-se um conjunto de 13 categorias, duas das quais inexistentes nos portais de origem.*

1. Introdução

Instituições voltadas à promoção da cultura e da educação na cidade de São Paulo, como SESC e as Fábricas de Cultura, desempenham um papel vital na democratização do acesso ao conhecimento. Para cumprir essa missão, essas organizações mantêm catálogos dinâmicos de atividades, abrangendo cursos, oficinas, palestras e apresentações artísticas.

No entanto, o volume expressivo e a alta rotatividade desses eventos, frequentemente temporários e com ciclos de vida curtos, geram o desafio logístico significativo que é a categorização adequada de cada atividade.

Atualmente, nota-se que a classificação adotada nos portais dessas instituições tende a ser genérica ou imprecisa. Categorias excessivamente amplas, como "Tecnologia e Artes", acabam agrupando atividades de naturezas distintas, como programação e pintura, dificultando a navegação de usuários que buscam interesses específicos. Essa barreira na busca por atividades não afeta todos os públicos da mesma maneira. Indivíduos com maior repertório cultural ou familiaridade com plataformas digitais conseguem filtrar as informações com mais facilidade, enquanto outros podem desistir da busca, evidenciando uma desigualdade estrutural no acesso à informação e, consequentemente, às oportunidades educacionais.

A motivação principal para este trabalho surgiu de um desafio prático enfrentado no desenvolvimento de um sistema de recomendação de atividades culturais, idealizado no semestre anterior para a disciplina de Teoria dos Grafos. Durante os testes daquele sistema, observou-se que diversas recomendações resultavam imprecisas aos usuários principalmente por conta da categorização pobre e generalista da base de dados original. Compreendeu-se, a partir dessa experiência, que a curadoria manual contínua de catálogos com alta rotatividade é inviável e custosa para as instituições. Além disso, abordagens tradicionais de busca por palavras-chave também se mostram insuficientes para suprir essa lacuna, pois falham em capturar a diversidade de vocabulário e o estilo (formal ou informal) presente nas descrições de cada atividade.

Nesse contexto, este artigo propõe o desenvolvimento de uma solução baseada em Inteligência Artificial, especificamente empregando técnicas de Processamento de Linguagem Natural (PLN). O objetivo central é criar um protótipo de API capaz de receber a descrição textual de uma atividade e, de forma automatizada, sugerir as categorias mais específicas e coerentes com seu conteúdo semântico. A abordagem utiliza *embeddings* gerados por um modelo de linguagem pré-treinado em português para capturar o sentido do texto como um todo, combinados a um classificador treinado com dados reais.

Com isso, espera-se contribuir para a otimização de sistemas de busca e recomendação no setor cultural. Ao facilitar a descoberta de eventos adequados ao perfil do usuário e auxiliar as instituições a alcançarem seu público-alvo com maior precisão, o projeto alinha-se diretamente aos Objetivos de Desenvolvimento Sustentável (ODS), em especial ao ODS 4 (Educação de Qualidade) e ao ODS 10 (Redução das Desigualdades) ao tornar mais acessível o conhecimento de oportunidades de enriquecimento cultural e educacional na cidade de São Paulo.

2. Fundamentação Teórica

A tarefa proposta pertence ao campo do Processamento de Linguagem Natural e depende, antes das etapas de aprendizado de máquina, da conversão do texto em uma representação numérica. As alternativas disponíveis para essa conversão diferem quanto ao que conseguem preservar do conteúdo original, e essa diferença orienta as escolhas descritas na metodologia.

A representação clássica é o TF-IDF, proposto no contexto de recuperação de informação por [Salton and Buckley 1988]. O método atribui a cada termo um peso pro-

porcional à sua frequência em um documento e inversamente proporcional à quantidade de documentos em que ele ocorre, de modo que termos muito distribuídos na coleção recebam peso reduzido. Trata-se de uma representação de baixo custo computacional e de interpretação direta, uma vez que cada posição do vetor corresponde a uma palavra conhecida. Sua limitação, no entanto, é relevante para o problema tratado neste trabalho: por operar sobre a forma escrita, o método não reconhece que dois textos tratam do mesmo assunto quando o vocabulário empregado é distinto.

A superação dessa limitação passou a ser possível com os modelos baseados em transformadores. O BERT [Devlin et al. 2019] representa cada termo em função do contexto em que ele aparece, e não de forma isolada, o que permite distinguir usos diferentes de uma mesma palavra. Para a comparação entre sentenças completas, contudo, o vetor obtido diretamente do modelo apresenta propriedades desfavoráveis, conforme demonstrado por [Li et al. 2020]. O Sentence-BERT [Reimers and Gurevych 2019] responde a esse ponto por meio de um ajuste com pares de sentenças semanticamente próximas e distantes, resultando em vetores que podem ser comparados entre si de maneira direta. É essa família de modelos, conhecida como codificadores de sentenças, que sustenta a abordagem adotada.

No caso do português, o BERTimbau [Souza et al. 2020] representa um avanço ao disponibilizar modelos treinados especificamente com textos em português do Brasil, com ganhos documentados em tarefas da língua. Persiste, entretanto, a característica de ser um modelo orientado a palavras, e não a sentenças. Os codificadores da família Serafim [Gomes et al. 2024] reúnem as duas propriedades desejadas para este trabalho, por serem treinados em português e voltados à comparação entre sentenças completas, além de distribuídos sob licença permissiva e em diferentes tamanhos.

A escolha entre modelos monolíngues e multilíngues não é consensual na literatura. [Feijo and Moreira 2020] compararam modelos monolíngues de português com suas versões multilíngues em seis tarefas da língua e concluíram que a vantagem do treinamento monolíngue, quando existente, é pequena. Em sentido distinto, o *benchmark* MTEB-PT [Okamura et al. 2026] constata que o desempenho em português é dependente da tarefa e que os rankings multilíngues não predizem de forma confiável o comportamento dos modelos na língua, o que desaconselha a seleção de um codificador apenas por sua posição em avaliações agregadas. O MTEB-BR [Stekel 2026], por sua vez, propõe um conjunto de tarefas nativas do português do Brasil, entre elas tarefas de agrupamento, próximas ao uso pretendido neste trabalho. Do confronto entre esses resultados extrai-se a orientação adotada neste trabalho: o idioma de treinamento, isoladamente, não constitui critério suficiente para a seleção de um codificador, devendo ser ponderado em conjunto com a adequação do modelo à tarefa pretendida e com as condições práticas de sua utilização, critérios detalhados na Seção 3.

Definida a representação, a etapa seguinte consiste em identificar grupos de atividades semelhantes. O algoritmo K-Means [MacQueen 1967] particiona os elementos em um número fixo de grupos por meio de um procedimento iterativo, no qual cada elemento é associado ao centro mais próximo e cada centro é reposicionado na média dos elementos associados a ele. A qualidade da partição obtida pode ser avaliada pelo coeficiente de silhueta [Rousseeuw 1987], que mede, para cada elemento, a diferença entre a distância ao próprio grupo e a distância ao grupo vizinho mais próximo.

A classificação pretendida é multirrótulo, uma vez que uma mesma atividade pode pertencer a mais de uma categoria simultaneamente. A estratégia prevista consiste em treinar um classificador binário por rótulo, o que permitirá que duas categorias sejam atribuídas ao mesmo item e fornecerá uma probabilidade independente para cada uma. Considerando o desbalanceamento observado na base, a acurácia global seria uma métrica pouco informativa, razão pela qual se pretende adotar o F1 por categoria, associado à separação entre conjuntos de treino e teste. Cabe registrar que essa etapa ainda não foi executada, integrando o planejamento descrito na Seção 3.

Quanto a trabalhos correlatos, o BERTopic [Grootendorst 2022] aborda problema semelhante ao aqui tratado, ao identificar temas em coleções de textos sem rotulação prévia. A solução proposta pelo autor agrupa documentos representados por *embeddings* e descreve cada tema por meio de uma variação do TF-IDF aplicada ao grupo. A abordagem deste trabalho compartilha o princípio de descrever grupos por seus termos mais característicos, mas incorpora uma etapa de nomeação manual, justificada pelo fato de que os rótulos resultantes serão exibidos a usuários finais em plataformas de busca. Não foram localizados trabalhos que tratem especificamente da classificação de atividades culturais e educacionais em português, o que reforça a pertinência da base construída.

3. Metodologia e Resultados Esperados

O desenvolvimento foi organizado em seis etapas: construção e caracterização da base de dados, preparação textual, geração das representações numéricas, agrupamento das atividades, definição das categorias e, por fim, treinamento do classificador multirrótulo com posterior conferência manual. As quatro primeiras etapas foram concluídas e são descritas a seguir.

Foram realizadas duas correções em relação à proposta apresentada na primeira parte deste projeto. Foi apresentado, naquele documento, que mais da metade das atividades seriam categorizadas como oficinas, proporção obtida a partir de uma coleta preliminar e reduzida; na base atual, a categoria "Cursos e Oficinas" corresponde a 175 das 1.034 atribuições de categoria, ou 17%. Além disso, a base prevista contemplava 526 atividades do SESC e 61 das Fábricas de Cultura, em duas unidades, enquanto a coleta mais recente reuniu 705 atividades distribuídas em 14 unidades.

3.1. Conjunto de dados

A base de dados foi construída pelo próprio grupo e reunia inicialmente 705 atividades divulgadas publicamente pelas Fábricas de Cultura [Fábricas de Cultura 2026] nas unidades Brasilândia, Capão Redondo, Jaçanã, Jardim São Luis, Núcleo Taipas e Vila nova Cachoeirinha e pelo Sesc São Paulo [Sesc São Paulo 2026] em oito unidades: Casa Verde, Santana, Consolação, Avenida Paulista, 14 Bis, Centro de Pesquisa e Formação, CineSesc e Pompeia. Após a estruturação das informações em formato tabular e a remoção de registros duplicados com o auxílio da biblioteca *Pandas*, a base consistiu em 693 itens únicos. Cada registro contém título, descrição, unidade, datas de realização e as categorias atribuídas pela instituição. Cumpre destacar que não há armazenamento de qualquer dado de caráter pessoal.

A etapa de extração foi implementada em Python, com o uso de bibliotecas específicas adaptadas à arquitetura de cada portal. Para o SESC, a programação é fornecida

por meio de uma API que retorna os dados em formato JSON. A biblioteca *Requests* foi utilizada para realizar as consultas aos *endpoints* de cada unidade; porém, como a descrição completa não faz parte dessa coleta inicial, utilizou-se a biblioteca *BeautifulSoup* para realizar a raspagem (*web scraping*) e extrair o texto completo diretamente do código HTML da página de cada atividade. Já o site das Fábricas de Cultura não disponibiliza um recurso de API equivalente, carregando seus dados de forma dinâmica. Para contornar essa limitação, adotou-se a biblioteca *Selenium* para realizar a automação de um navegador web, simulando interações de clique no botão de carregamento até a exibição integral e coleta por raspagem do catálogo de eventos.

A coleta referente ao SESC ocorreu em duas execuções com um intervalo de apenas dois dias, ação motivada pelo rigor metodológico de atualizar a base e garantir a captura da programação mais recente na plataforma. O cruzamento dessas duas extrações revelou um dado analítico relevante: 81 registros presentes na primeira coleta (equivalentes a 14,4% do total de 564 atividades exclusivas do SESC) haviam expirado e deixaram de ser exibidos no portal dentro dessa breve janela de 48 horas. Embora isso represente uma perda de volume para a composição da base de testes, esse acontecimento fornece a medida exata da alta rotatividade apontada na introdução do trabalho. Se em dois dias, uma parcela tão expressiva do catálogo sai do ar, comprova-se materialmente que a curadoria manual contínua para manutenção das categorias é inviável para as instituições. O script publicado no repositório reproduz o fluxo unificado utilizado para a consolidação final dos dados.

3.2. Análise exploratória

As duas instituições empregam, em conjunto, 36 categorias distintas, distribuídas em 1.034 atribuições, dado que uma atividade do SESC pode receber mais de uma. A distribuição é acentuadamente desigual, conforme a Figura 1: as três categorias mais frequentes concentram 40,7% das atribuições, ao passo que 13 das 36 aparecem em cinco atividades ou menos. No âmbito das Fábricas de Cultura, a categoria "Biblioteca" responde isoladamente por 31% das atividades. Registra-se ainda que 81 atividades, ou 11,7% da base, não possuem categoria alguma.

Três evidências quantitativas indicam a inadequação dessas categorias como referência de treinamento.

A primeira refere-se à sobreposição. Cada atividade recebe, em média, 1,69 categoria, e o par mais frequente é composto por "Cursos e Oficinas" e "Tecnologias e Artes", categorias genéricas, que ocorrem conjuntamente 72 vezes. A categoria "Encontros e Palestras" consta em 98 atividades e, em 87 delas, acompanhada de outra categoria, o que indica que isoladamente ela não descreve o conteúdo da atividade.

A segunda diz respeito à natureza heterogênea dos rótulos. A leitura individual das 36 categorias permitiu verificar que oito delas apontam a linguagem artística, a exemplo de "Música" e "Dança"; seis apontam o formato do evento, como "Cursos e Oficinas" e "Mostras e Exposições"; cinco apontam o tema, como "Esporte e Atividade Física"; e uma aponta o setor responsável pela realização, no caso "Biblioteca". Como todas integram a mesma lista de filtros, o usuário não dispõe de meios para identificar qual critério está sendo aplicado.

A terceira evidência é a divergência entre o rótulo atribuído e o conteúdo textual.




Figura 1. Distribuição das atividades entre as categorias publicadas pelas instituições.

O termo "oficina" ocorre na descrição de 83 atividades e em alguma categoria de 189 atividades, verificando-se coincidência entre ambos em apenas 46 casos.

A comparação entre as listas das duas instituições evidencia um obstáculo adicional, relevante para uma solução deverá se tornar aplicável a instituições diversas: o SESC utiliza 24 categorias e as Fábricas de Cultura, 19, das quais apenas sete são grafadas de forma idêntica, a saber, Artes Visuais, Cinema, Circo, Dança, Literatura, Música e Teatro. Observam-se ainda pares semanticamente próximos e formalmente distintos, como "Oficina" e "Cursos e Oficinas", ou "Exposições" e "Mostras e Exposições". Foi constatado que a integração de catálogos sob as classificações já existentes exigiria a definição prévia de uma nomenclatura comum, o que integra o objetivo deste trabalho.

Quanto às características textuais, as descrições do SESC são consideravelmente mais extensas, com mediana de 118,5 palavras, contra 71 palavras nas Fábricas de Cultura. Tal diferença é relevante porque representações baseadas em contagem de termos tendem a aproximar textos longos entre si.

3.3. Preparação dos dados

O texto submetido aos modelos é composto pelo título seguido da descrição, escolha justificada pelo fato de o título sintetizar o assunto e a descrição detalhá-lo. Foram removidos 12 registros duplicados, correspondentes a atividades realizadas em mais de uma unidade, procedimento executado antes da separação entre treino e teste a fim de evitar que a mesma atividade integre ambos os conjuntos. Optou-se por não aplicar limpezas adicionais ao texto: expressões recorrentes como "com equipe biblioteca" poderiam ser suprimidas, mas tal tratamento é específico das instituições já conhecidas e não se susten-

taria diante de uma instituição nova.

A divisão entre treino e teste adota a proporção de 80% e 20%, com semente fixa, e é registrada em uma coluna da própria tabela em vez de ser sorteada novamente a cada execução, garantindo que a avaliação ocorra exatamente sobre os registros mantidos à parte desde o início.

3.4. Representação do texto

Para a representação por TF-IDF, foram avaliadas duas configurações antes da definição. Sem a remoção das palavras funcionais do português, os dez termos de maior peso médio na base eram integralmente preposições e artigos, e a similaridade média entre pares de atividades era de 0,0515; com a remoção, esse valor reduziu para 0,0196, o que evidencia que parte considerável da semelhança aparente decorria de termos sem conteúdo informativo. Adotou-se, portanto, a configuração com remoção, resultando em vocabulário de 11.188 termos.

Para a geração dos *embeddings* adotou-se o modelo Serafim de 335 milhões de parâmetros [Gomes et al. 2024], que produz vetores de 1.024 dimensões. A seleção considerou quatro critérios. O primeiro é o treinamento em português, conforme previsto na proposta inicial. O segundo é o treinamento voltado especificamente à comparação entre sentenças, requisito da etapa de agrupamento e da API pretendida. O terceiro é a distribuição sob licença permissiva e sem exigência de credenciais de acesso, condição necessária à reprodutibilidade dos experimentos por terceiros. O quarto é a viabilidade de execução em equipamento comum, sem unidade de processamento gráfico.

Modelos multilíngues amplamente utilizados foram recusados em função do segundo *benchmark* citado na fundamentação [Okamura et al. 2026], ainda que seja reconhecido, conforme [Feijo and Moreira 2020], que a superioridade de modelos monolíngues não seja garantida. Cabe observar que a escolha não se apoiou exclusivamente no idioma, mas também nos demais critérios enumerados. Modelos de maior porte foram descartados por incompatibilidade com o tempo de resposta esperado de uma API, e modelos de distribuição restrita foram descartados por comprometerem a reprodutibilidade. Não foram conduzidos experimentos comparativos com todos os candidatos sobre a base deste trabalho; a seleção foi fundamentada nas características dos modelos e nos *benchmarks* publicados, complementados por uma verificação conduzida sobre a própria base.

Essa verificação consistiu em agrupar a base duas vezes, uma com o modelo adotado e outra com um modelo multilíngue de referência. O modelo em português produziu grupos de tamanhos mais equilibrados, entre 17 e 64 atividades, enquanto o multilíngue concentrou 117 atividades em um único grupo e isolou apenas seis em outro. Esse equilíbrio foi determinante para a escolha, uma vez que grupos muito desiguais dificultariam a etapa de nomeação manual. O coeficiente de silhueta também foi superior no modelo em português, 0,0425 ante 0,0192.

A construção da matriz TF-IDF para as 693 atividades levou menos de um segundo, enquanto a geração dos *embeddings* demandou 320 segundos em equipamento sem unidade de processamento gráfico, o que equivale a aproximadamente meio segundo por atividade. Esse custo é pago uma única vez na preparação da base, mas voltaria a incidir a cada nova atividade submetida à API, razão pela qual foi considerado na escolha

do modelo: codificadores de maior porte, ainda que mais precisos, produziram tempo de resposta incompatível com o uso pretendido.

3.5. Agrupamento e definição das categorias

As atividades foram agrupadas por K-Means sobre ambas as representações, com semente fixa e 16 grupos em cada configuração. O coeficiente de silhueta foi calculado para quantidades de grupos entre 4 e 20, conforme a Figura 2, tendo-se obtido valores próximos de zero em todas as configurações testadas. Tal resultado indica que as atividades não formam agrupamentos nitidamente separados, comportamento esperado em coleções textuais. Por essa razão, o coeficiente não foi utilizado como critério de escolha da quantidade de grupos, definida em 16 por corresponder ao volume que a equipe conseguiria examinar integralmente na etapa seguinte.




Figura 2. Coeficiente de silhueta médio por quantidade de grupos nas duas representações.

A definição dos nomes das categorias foi realizada manualmente. Para cada grupo foram examinados os termos de maior peso e os títulos das atividades correspondentes, atribuindo-se em seguida uma denominação. Grupos que tratavam do mesmo assunto receberam a mesma denominação e foram consolidados. Duas diretrizes orientaram essa etapa, ambas derivadas dos problemas identificados na análise exploratória: nomear pelo assunto da atividade, evitando designações relativas ao formato ou ao setor responsável, e evitar denominações de abrangência excessiva, que reproduziriam o comportamento observado em "Encontros e Palestras".

3.6. Etapa subsequente e resultados esperados

A etapa seguinte consiste no treinamento do classificador multirrótulo sobre as categorias definidas, com um modelo binário por rótulo, comparando-se regressão logística, máquinas de vetores de suporte e redes neurais do tipo MLP sobre as duas representações, com validação cruzada e F1 por categoria. Prevê-se igualmente a mensuração do custo computacional de cada configuração e a análise dos termos de maior peso em cada categoria. A validação final será conduzida por conferência manual sobre um conjunto reduzido de atividades não utilizadas no treinamento.

Espera-se que a representação por *embeddings* supere a representação por contagem de termos tanto na coerência dos agrupamentos quanto no desempenho do classificador, e que o conjunto de categorias resultante descreva atividades das duas instituições sob uma mesma nomenclatura, o que não ocorre atualmente. Espera-se ainda desempenho desigual entre categorias, superior nas mais numerosas e inferior nas menos representadas, em decorrência do desbalanceamento da base.

4. Resultados Parciais

4.1. Aspectos éticos e responsabilidade no uso da IA

O sistema proposto interfere diretamente naquilo que é apresentado ao usuário que busca uma atividade, e uma classificação equivocada produz consequência dupla: a atividade deixa de ser encontrada por quem teria interesse nela, e a instituição perde alcance precisamente onde pretendia ampliá-lo.

O risco mais concreto identificado neste trabalho é o viés decorrente da origem dos dados, e ele não constitui hipótese, tendo sido mensurado. A base provém de duas instituições da cidade de São Paulo, e o agrupamento das atividades revelou que parte dos grupos se organiza segundo a instituição de origem, e não segundo o assunto, conforme detalhado na subseção seguinte. Compreende-se que o modelo incorpora também o estilo de redação de quem publicou o texto. A consequência prática é que uma instituição de menor porte, situada em outra região e com padrão de escrita distinto, tende a ser classificada com menor precisão justamente por não reproduzir o padrão das instituições presentes no treinamento. Considerando que o protótipo é concebido de modo a poder ser integrado por qualquer instituição que publique esse tipo de atividade, esse risco deve ser explicitado e monitorado desde a construção da base, e não constatado apenas em um cenário de adoção efetiva.

Há ainda o risco de a classificação automática reduzir a visibilidade de atividades que não se acomodam bem às categorias majoritárias. Atividades vinculadas à cultura periférica, a povos indígenas e a comunidades negras estão presentes na base e constituíram grupo próprio no agrupamento. A eventual absorção desse grupo por uma categoria mais genérica, em versões futuras do sistema, dificultaria sua localização. Um sistema destinado a organizar produção cultural deve, portanto, considerar aquilo que ele torna menos visível.

Em decorrência dessas considerações, adotou-se como diretriz que a classificação automática não substitua a decisão humana, mas a apoie. Uma vez que a saída do classificador consiste em uma probabilidade por categoria, a API pode retornar a categoria sugerida acompanhada de um alerta quando a probabilidade mais elevada for baixa, indicando a conveniência de revisão humana. Dessa forma, o sistema sinaliza a própria incerteza em vez de produzir uma atribuição equivocada de modo silencioso, preservando a decisão final com a instituição responsável pela publicação.

Quanto à origem dos dados, utilizou-se exclusivamente informação pública de programação cultural, sem qualquer dado pessoal, e os scripts de coleta estão disponíveis no repositório do projeto, permitindo a verificação do que foi efetivamente obtido. Quanto ao uso de ferramentas de IA generativa na elaboração deste trabalho, houve emprego de assistente de IA para apoio na compreensão de conceitos e materiais da disciplina,

na aprendizagem de novas técnicas de raspagem de dados, na revisão de texto e na organização do código, mantendo-se com o grupo a concepção da proposta, as decisões metodológicas, codificação de experimentos e a análise dos resultados, conforme declarado na primeira parte deste projeto.

4.2. Agrupamento por TF-IDF e o vazamento da instituição de origem

A verificação da composição dos grupos formados a partir do TF-IDF revelou um problema relevante. Considerando que o SESC corresponde a 81,4% da base, um agrupamento indiferente à origem institucional ainda apresentaria essa proporção no interior dos grupos. O valor observado, contudo, foi de 89,3%, com 11 dos 16 grupos compostos em 90% ou mais por uma única instituição. O exame dos termos característicos revelou a presença de "sesc" e de "equipe", este último proveniente da expressão "com equipe biblioteca", utilizada exclusivamente pelas Fábricas de Cultura. Tais termos não descrevem o conteúdo das atividades, mas identificam quem redigiu o texto.

Foi avaliada, então, a remoção desses termos do vocabulário. A concentração reduziu-se a 86,1%, com sete grupos compostos majoritariamente por uma instituição, o que configura melhoria parcial: a marca institucional é distribuída pelo estilo de redação como um todo, e não em um conjunto restrito de palavras.

Cabe destacar, que tal correção não é aplicável ao sistema proposto. A API recebe descrições provenientes de instituições potencialmente desconhecidas, e não há como estabelecer previamente a lista de termos a serem removidos de uma instituição que ainda não utilizou o serviço. O procedimento funciona apenas porque a origem dos dados é conhecida de antemão. Na representação por *embeddings* a questão não se coloca, visto que não existe operação equivalente à remoção de um termo em um vetor semântico.

4.3. Agrupamento por *embeddings*

Aplicado o mesmo procedimento de verificação à representação por *embeddings*, sem qualquer remoção de termos, obteve-se concentração por instituição de 83,5%, mais próxima dos 81,4% correspondentes à ausência de vazamento, com oito dos dezesseis grupos majoritariamente compostos por uma única instituição. Os resultados obtidos neste trabalho indicam, portanto, que a representação principal supera o TF-IDF mesmo quando este é auxiliado por um procedimento inaplicável em produção.

As duas representações também divergem quanto às atividades que consideram semelhantes. A atividade "Bê-a-Bá Digital: Módulo II" ilustra essa diferença: o TF-IDF aponta "Projetos Livres" como a mais similar a ela, enquanto o modelo de *embeddings* aponta "Plantão de dúvidas: Bê-a-bá digital", atividade que trata do mesmo assunto ainda que empregue vocabulário distinto.

4.4. Categorias obtidas

O exame dos 16 grupos resultou em 13 categorias, apresentadas na Tabela 1. A consolidação ocorreu em dois casos: atividades esportivas, distribuídas em três grupos, e apresentações ao vivo, distribuídas em dois.

Tabela 1. Categorias obtidas a partir do agrupamento das descrições.

Categoria	Atividades
Esporte	135
Shows, Espetáculos e Performances	87
Artes Visuais	64
Cinema	56
Sociedade e Debates	54
Atividade Física e Bem-Estar	54
Infância e Brincadeiras	48
Literatura e Leitura	45
Artesanato	40
Cultura e Identidade	36
Música	36
Reciclagem e Sustentabilidade	21
Plantas e Alimentação	17

Duas dessas categorias não constam das listas de nenhuma das duas instituições e constituem o resultado parcial de maior interesse obtido até o momento, ilustrado na Figura 3.

A categoria "Reciclagem e Sustentabilidade" reúne 21 atividades, entre as quais "Sustentabilidade e reciclagem", "Oficina criativa" da Virada Sustentável e "Virada Sustentável: painel sonoro com material reciclável". Nos portais de origem, essas mesmas atividades encontravam-se classificadas como Biblioteca, Oficina e Artes Cênicas, designações que nada informam sobre o assunto tratado. A categoria "Plantas e Alimentação" reúne 17 atividades, tais como "Plantas medicinais: saberes, usos e cuidados", "Manejo agroecológico" e "Feira agroecológica e da Agricultura Familiar".




Figura 3. Distribuição das atividades entre as categorias obtidas neste trabalho.

Ambas correspondem a interesses que um usuário buscaria e que, na organização vigente, permanecem ocultos sob rótulos referentes ao setor responsável ou ao formato do evento. As categorias surgiram exclusivamente da organização espontânea das atividades

no espaço semântico, sem definição prévia, o que confere sustentação parcial à hipótese formulada na proposta inicial deste projeto.

4.5. Limitações

Parte das descrições publicadas combina o texto descritivo da atividade com instruções operacionais de inscrição. No agrupamento por TF-IDF, tal característica produziu grupos definidos por termos como "inscrição", "preenchidas" e "credencial", ou seja, grupos constituídos pelo texto administrativo e não pelo conteúdo da atividade. O tratamento desse tipo de trecho está previsto para a etapa seguinte.

O vazamento de origem manifesta-se também em nível de unidade, e não apenas de instituição. Um dos grupos obtidos reúne 38 de suas 54 atividades em uma única unidade do SESC, o Centro de Pesquisa e Formação, responsável pela programação de cursos e seminários e detentora de padrão próprio de redação.

Uma limitação adicional refere-se ao classificador previsto. No conjunto de treinamento, cada atividade está associada a uma única categoria, que é a do grupo em que foi alocada. O modelo multirrótulo, entretanto, poderá atribuir duas ou mais categorias a uma atividade nova. Isso significa que ele poderá produzir combinações de categorias que nunca observou durante o treinamento, e a base atual não oferece exemplo algum que indique quais combinações seriam adequadas. Esse comportamento será verificado na conferência manual, aplicada a atividades que não participaram do treinamento.

Por fim, as categorias utilizadas como referência não são externas a este trabalho: foram obtidas pelo agrupamento e nomeadas pela própria equipe. Avaliar o classificador apenas contra esses rótulos verificaria se o modelo reproduz o agrupamento que lhe deu origem, e não se a classificação resultante é adequada às atividades. Por esse motivo, a conferência manual sobre atividades não utilizadas no treinamento constitui etapa necessária, e não complementar.

4.6. Repositório do projeto

O material completo do projeto, incluindo os dados coletados, os scripts de coleta, os notebooks com os resultados das análises e o presente artigo, encontra-se disponível publicamente em:

<https://github.com/Andrade-Julia/Projeto-Inteligencia-Artificial>

Referências

- Devlin, J., Chang, M.-W., Lee, K., and Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics*, pages 4171–4186, Minneapolis.
- Feijo, D. d. V. and Moreira, V. P. (2020). Mono vs multilingual transformer-based models: a comparison across several language tasks. *arXiv preprint arXiv:2007.09757*.
- Fábricas de Cultura (2026). Programação cultural. <https://www.fabricasdecultura.org.br/programacao-cultural/>. Acesso em: 25 set. 2026.

- Gomes, L., Branco, A., Silva, J., Rodrigues, J., and Santos, R. (2024). Open sentence embeddings for Portuguese with the Serafim PT* encoders family. In *Progress in Artificial Intelligence (EPIA 2024)*, pages 267–279, Cham. Springer.
- Grootendorst, M. (2022). BERTopic: Neural topic modeling with a class-based TF-IDF procedure. *arXiv preprint arXiv:2203.05794*.
- Li, B., Zhou, H., He, J., Wang, M., Yang, Y., and Li, L. (2020). On the sentence embeddings from pre-trained language models. *arXiv preprint arXiv:2011.05864*.
- MacQueen, J. (1967). Some methods for classification and analysis of multivariate observations. In *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability*, pages 281–297. University of California Press.
- Okamura, L. H. T., Alcoforado, A., and Reali Costa, A. H. (2026). Beyond multilingual averages: MTEB-PT, a benchmark for Portuguese sentence encoders. *arXiv preprint arXiv:2607.04071*.
- Reimers, N. and Gurevych, I. (2019). Sentence-BERT: Sentence embeddings using siamese BERT-networks. In *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing*, pages 3982–3992, Hong Kong.
- Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, 20:53–65.
- Salton, G. and Buckley, C. (1988). Term-weighting approaches in automatic text retrieval. *Information Processing and Management*, 24(5):513–523.
- Sesc São Paulo (2026). Programação. <https://www.sescsp.org.br/programacao/>. Acesso em: 25 set. 2026.
- Souza, F., Nogueira, R., and Lotufo, R. (2020). BERTimbau: Pretrained BERT models for Brazilian Portuguese. In *Intelligent Systems (BRACIS 2020)*, pages 403–417. Springer.
- Stekel, T. R. C. (2026). MTEB-BR: A text embedding benchmark for Brazilian Portuguese. *arXiv preprint arXiv:2607.04581*.